

Predicción de Eventos de Epilepsia Utilizando Deep Learning y Redes Neuronales Convolucionales (RNC) para el Análisis de Electroencefalogramas (EEGs)

Alexis Vázquez Martínez & Dr. José Antonio Cantoral

Abstract—

El estudio de las señales cerebrales mediante Electroencefalogramas (EEGs), ha sido popular desde hace un buen tiempo para estudiar principalmente ataques epilépticos y desordenes del sueño, esto debido a ser señales muy sencillas de obtener y por ser no invasivas. Ya se han llegado a investigar con anterioridad algoritmos que permitan predecir ataques de epilepsia en pacientes, sin embargo estas investigaciones han estado enfocadas principalmente en el análisis de señales crudas y además no cuentan con suficiente sustento para su uso terapéutico. Ésta investigación pretende realizar un nuevo acercamiento y desarrollar un algoritmo mediante técnicas de deep learning, para analizar señales representadas como imágenes, siendo estas obtenidas de EEGs transformadas en espectrogramas para su posterior análisis mediante una red neuronal convolucional de 2 dimensiones.

I. INTRODUCCIÓN

La epilepsia es una enfermedad cerebral crónica, que afecta hasta 50 millones de personas en el mundo y que posee una mayor concentración de casos en países en desarrollo, se caracteriza por generar convulsiones, ya sean parciales o totales y que pueden acompañarse con la pérdida del conocimiento y/o control de esfínteres[1], al ser un padecimiento en el cerebro humano que se manifiesta como señales eléctricas, puede ser detectada mediante análisis de señales provenientes de EEGs[2], los EEGs (Electroencefalogramas) son pruebas que detectan la actividad eléctrica del cerebro mediante pequeños discos metálicos (electrodos) fijados sobre el cuero cabelludo, ya que detecta los pequeños impulsos eléctricos generados por las neuronas, las cuales están activas todo el tiempo.[3]


Las convulsiones causadas por la epilepsia, pueden provocar problemas tanto emocionales como físicos[9], estos últimos son principalmente ocasionados al momento del ataque y pueden tener graves consecuencias al ocurrir en momentos específicos y generar desde ahogamientos hasta accidentes automovilísticos. Estas convulsiones, son caracterizadas por cambios temporales en el funcionamiento bioeléctrico del cerebro[4], afectando así la conciencia, el movimiento o la sensibilidad.

El análisis de electroencefalogramas ha sido una herramienta importante en la neurociencia con aplicaciones importantes

en la ingeniería neural, la neurociencia e incluso ha tenido aplicaciones comerciales[5]. Muchas de las herramientas de análisis utilizadas en el estudio de EEGs han utilizado machine learning para descubrir información relevante para la clasificación neural y el mapeo de neuroimágenes.[5]. La disponibilidad de información ocurrida en años recientes y en específico la disponibilidad de grandes datasets de EEGs, han permitido generar diversas arquitecturas de análisis utilizando diferentes técnicas de deep learning. La investigación llamada *Deep Learning in EEG: Advance of the Last Ten-Year Critical Period*, propone que los últimos 10 años han sido cruciales para las investigaciones sobre clasificación de EEGs utilizando deep learning y hace mención a que no solamente existen más publicaciones, sino que las publicaciones recientes muestran cada vez mejores resultados, con respecto a su clasificación y su análisis a través del tiempo[6], de igual manera hace mención a que se dejó de hacer análisis a las EEGs crudas para analizarlas mediante diferentes técnicas como la extracción de imágenes tomadas en pequeños periodos de tiempo, debido a la variabilidad de la señal durante la obtención de la misma. La investigación además menciona las características del uso de una red neuronal convolucional y la necesidad del pre-procesamiento de datos para el ingreso de imágenes a la misma[6]. Una red neuronal convolucional (RNC) es un algoritmo basado en deep learning que permite tomar una imagen como entrada para posteriormente poder clasificarla dependiendo de sus características[7].

A pesar de ser un tema de estudio recurrente dentro de las aplicaciones de deep learning en la salud[10], demostrado por la investigación *Journal of Biomedical and Health Informatics*, aún quedan ambigüedades en el uso del procesamiento de imágenes para analizar patrones que permitan predecir algún comportamiento o patrón en el cerebro, por lo que este trabajo, pretende utilizar redes neuronales convolucionales para la predicción de ataques de epilepsia con espectrogramas como entrada de la red neuronal, cada uno utilizando diferentes canales y diferentes periodos de tiempo para su generación. La investigación *EEG Channel-Selection Method for Epileptic-Seizure Classification Based on Multi-Objective Optimization*, utilizó la misma base de datos utilizada en esta investigación para desarrollar un método que permita optimizar la selección de canales para obtener los datos más óptimos que permitan un alto grado de precisión, por

Fig. 1. Representación de un ataque de epilepsia



lo que sirve como referente para selección de los pacientes y la clasificación de sus señales[8].

Otras investigaciones ya han abordado la posibilidad de utilizar imágenes como entrada de la red neuronal, como el libro *EEG Signal Processing and Feature Extraction*, que permite entender a grandes rasgos el análisis de imágenes en EEGs y el éxito de los resultados que pueden ser obtenidos[11], sin embargo no se realiza una comparación profunda entre diferentes modelos de análisis y por lo tanto, sustenta el hecho de que procesar los datos como imágenes es un excelente acercamiento pero no demuestra una efectividad superior al análisis de datos crudos, por dar un ejemplo. La investigación *A review of channel selection algorithms for EEG signal processing*[12], similar a otra mencionada anteriormente, busca estrategias para seleccionar los datos de entrada que presenten una calidad más adecuada para el análisis de datos y su representación. La investigación *EEG Source Imaging: A Practical Review of the Analysis Steps*, menciona en sus hallazgos, las limitantes y los obstáculos en las decisiones que se deben tomar al delimitar las muestras de la investigación y explica cómo podría realizarse una interpretación visual de los datos[13].

II. DATOS Y METODOLOGÍA

II-A. Base de datos de EEGs

El dataset utilizado en esta investigación, *CHB-MIT Scalp EEG Database 1.0.0*, pertenece a una investigación previa desarrollada por el MIT[14] publicada el 9 de Junio del 2009, en la que se recolectó información del Boston Children's

Hospital perteneciente a 22 pacientes, 5 de sexo masculino y 17 de sexo femenino, con todos los pacientes de entre 1.5 y 22 años de edad. Los registros de los pacientes fueron agrupados en 23 casos. Todas las señales fueron muestreadas a 256 muestras por segundo, en una resolución de 16 bits. Los registros analizan tanto señales pertenecientes a la fase Interictal, que es la fase entre ataques de epilepsia[15], como a la fase preictal[16], que es la fase justo previa a un ataque de epilepsia, y la fase Ictal[17], que es la fase perteneciente al ataque en sí. Los registros se encuentran en formato .edf y entre ellos se incluyen 198 ataques de epilepsia identificados en un resumen de archivos, por lo que se facilita su lectura y su interpretación. La figura 1 muestra un electroencefalograma justo en el momento que ocurre un ataque de epilepsia.

II-B. Lectura de datos y señales


Para la lectura de las señales en formato edf, la transformación a espectrogramas y su análisis en el modelo, se utilizó python como principal herramienta, junto a las librerías *mne*, *torch*, *scipy* y *OS* para la lectura y manipulación de archivos.

II-C. Pre-procesamiento

II-C.1. Selección de información: Lo primero a desarrollar fue la selección de pacientes y canales que contaran con la mejor calidad para su análisis. Basado en los descubrimientos de de la investigación ya antes mencionada *EEG Channel-Selection Method for Epileptic-Seizure Classification Based on Multi-Objective Optimization*[8], se optó por seleccionar 19 pacientes:

['chb01', 'chb02', 'chb03', 'chb04', 'chb05', 'chb06',

Fig. 2. Representación visual de un espectrograma tomado de la investigación *Method for Semi-Automated Evaluation of User Experience Using Brain Activity*[20]



'chb07', 'chb08', 'chb09', 'chb10', 'chb11', 'chb14', 'chb17', 'chb18', 'chb19', 'chb20', 'chb21', 'chb22', 'chb23']

y 18 canales:

['FP1-F7', 'F7-T7', 'T7-P7', 'P7-O1', 'FP1-F3', 'F3-C3', 'C3-P3', 'P3-O1', 'FP2-F4', 'F4-C4', 'C4-P4', 'P4-O2', 'FP2-F8', 'F8-T8', 'T8-P8-O', 'P8-O2', 'FZ-CZ', 'CZ-PZ'] para su conversión a espectrogramas. Todos los pacientes seleccionados contaban con al menos 3 registros de ataques de epilepsia y con varias horas de grabación. Cada uno de los pacientes contaba con un archivo *summary.txt* en el que se encontraba información sobre las grabaciones y sobre los ataques presentes en ellas, éste archivo se utilizó más adelante para seleccionar los registros y crear sus espectrogramas basándose en sus especificaciones.

Se definió la fase preictal para esta investigación como los 20 minutos previos al ataque, creando para Los espectrogramas a realizar se crearon con ventanas de 60 segundos y tomando la fase preictal como los 20 minutos previos al ataque.

II-C.2. Espectrogramas: Para la obtención de espectrogramas se utilizó el archivo *summary.txt* de los pacientes seleccionados, en el que se encontraba información referente a los pacientes, los registros y las características de las muestras. De ese archivo, se tomó la información sobre de cada uno de los registros, para primero clasificar cuales contaban con ataques. Posterior a esto, se crearon espectrogramas primero con toda la información de cada paciente, se crearon utilizando la información

Fig. 3. Ejemplo archivo *summary.txt*


```
File Name: chb01_01.edf
File Start Time: 11:42:54
File End Time: 12:42:54
Number of Seizures in File: 0

File Name: chb01_02.edf
File Start Time: 12:42:57
File End Time: 13:42:57
Number of Seizures in File: 0

File Name: chb01_03.edf
File Start Time: 13:43:04
File End Time: 14:43:04
Number of Seizures in File: 1
Seizure Start Time: 2996 seconds
Seizure End Time: 3036 seconds
```

completa de la muestra, por lo que el desarrollo de este espectrograma se hizo tomando en cuenta cada registro con todos sus canales y verificando que efectivamente no hubiera problema en la lectura de los mismos. Se eliminaron las frecuencias entre los rangos de 57 a 64 Hz y de 117 a 124 Hz para eliminar las interferencias causadas por la línea eléctrica.

Fig. 4. Modelo RNC



Posteriormente, y como ya se mencionó, se tomaron bloques de 60 segundos para crear las ventanas, esto debido a que la investigación *A Comparative Study of Window Size and Channel Arrangement on EEG-Emotion Recognition Using Deep CNN*[18] establece que un análisis más detallado de cada ventana genera mejores resultados en su análisis y debido a esto se partieron todos los espectrogramas generados anteriormente para crear espectrogramas independientes con y sin overlap, debido a que son pocas y el overlap se preparó para una mayor cantidad de muestras, tomando algunos de los casos y colocándolos como datos de prueba para su posterior análisis. El resto del tiempo se clasificó como inter-ictal y de aquí se tomaron muestras de manera aleatoria para conformar el grupo de pruebas.

II-D. Modelo

El modelo convolucional propuesto en esta investigación, se preparó tomando los espectrogramas generados anteriormente e ingresándolos en 5 capas convolucionales de 2 dimensiones, con un kernel de 3x3 y una salida de 64 canales cada una, aplicando batch normalization a cada salida de las capas convolucionales y utilizando función de activación de tipo ReLu[19], para al finar procesarlas por una última capa fully connected y obtener la decisión final de la red. Se utilizaron capas de activación de tipo ReLu debido a la eficiencia al delimitar los datos y al rendimiento que pudiera generar para la salida de datos.

III. EVALUACIÓN Y RESULTADOS

Para obtener los resultados del desempeño de la red neuronal convolucional, se midió la exactitud de la misma, una vez entrenada con el conjunto de datos de entrenamiento, se verificó utilizando el conjunto de datos de prueba y se registró cuantas muestras acertó y se dividió entre el total, obteniendo

el porcentaje de exactitud. El entrenamiento del modelo se realizó en 5 épocas con los nuevos espectrogramas de entrenamiento como entradas, un optimizador de tipo adam[21] para la optimización del descenso de gradientes[22] y un *learning-rate*[23] de $3.5e-7$ como parámetro para controlar los cambios del modelo respecto al error.

Los resultados obtenidos se realizaron obteniendo algunas pruebas, la primera fue conformada por el análisis de 19 pacientes y 18 canales, en la cual se obtuvo una efectividad del 65 % en el conjunto de entrenamiento, mientras que en el de pruebas, esta fue del 56 %.

Una segunda prueba se llevó a cabo utilizando menos pacientes y menos canales, 10 y 10 respectivamente, al revisar los resultados estos fueron más prometedores, obteniendo una efectividad del 74 % en el conjunto de pruebas y del 72 % en el conjunto de entrenamiento. Aunque parece ser un buen acercamiento, el modelo podría llegar a conclusiones erróneas al evaluar señales de pacientes fuera de la muestra, por lo una prueba con esta información sería necesaria para llegar a una conclusión certera.

Una tercera prueba se llevó a cabo ingresando una capa extra de max-pooling[24] al modelo, esto para proveer de una capa de reducción de los parámetros y del tiempo de ejecución computacional[25]. Los resultados de esta tercer prueba fueron similares e incluso más bajos a la primera prueba, con un 65 % de efectividad en el conjunto de entrenamiento y un 55 % de efectividad en el conjunto de pruebas.

La evaluación de los resultados se hizo mediante el promedio de la cantidad de predicciones, clasificándolas como correctas o incorrectas al recibir el modelo y los conjuntos de entrenamiento y de pruebas respectivamente.

IV. DISCUSIÓN Y CONCLUSIONES

El modelo convolucional propuesto, logró obtener resultados significativos, sin embargo se espera que nuevas investigaciones puedan lograr obtener números aún mayores

para su futuro uso terapéutico. Esta investigación, por su índole y el tipo de datos, pudo ser guiada en conjunto con un especialista médico para entender mejor el comportamiento de las señales y las fluctuaciones de las muestras en los periodos de tiempo, por lo que se espera que más adelante se pueda contar con este tipo de apoyo para posibles contribuciones en la metodología y para su aplicación en un caso real.

Es importante mencionar que para la elaboración de esta investigación, la generación de espectrogramas, la base de datos y la experimentación, se utilizó un tamaño en disco de 256 GB por lo que se entiende que un procesamiento en la nube consumiría muchos recursos de almacenamiento.

Fig. 5. Espacio ocupado local

Tamaño: 269 GB (289,060,980,199 bytes)
 Tamaño en disco: 269 GB (289,184,595,968 bytes)
 Contiene: 68,189 archivos, 126 carpetas

El hardware utilizado en la investigación contenía un procesador intel i5 de octava generación y no contaba con una unidad de procesamiento gráfico, por lo que otra limitante que existió fueron los tiempos de ejecución tanto del modelo, la validación y la conversión a espectrogramas, llegando hasta 18 horas continuas en su ejecución desde el principio. Se espera que con GPU el procesamiento sea mucho más rápido que con CPU y probablemente su ejecución utilizando cloud computing pudo haber sido mucho más eficiente y pudieron haberse realizado más pruebas con diferentes entradas y salidas en el modelo, además de una mayor configuración de los parámetros, como la longitud de ventanas, la cantidad de pacientes, la cantidad de canales y el periodo definido como preictal para la realización de espectrogramas más precisos.

Se espera que esta investigación pueda apoyar a su uso terapéutico en un futuro cercano, haciendo uso del modelo dentro de un dispositivo que permita analizar señales en tiempo real, utilizando de igual manera electroencefalogramas no invasivos y los mismos canales de entrada en los electrodos.

REFERENCES

- [1] ORGANIZACIÓN MUNDIAL DE LA SALUD, OMS — Epilepsia, Ciencia, 2016. Disponible en <https://www.who.int/es/news-room/fact-sheets/detail/epilepsy>
- [2] CLEVELAND CLINIC, Electroencefalogram (EEG), Neurología, S/F, Disponible en <https://my.clevelandclinic.org/health/diagnostics/9656-electroencefalogram-eeeg>
- [3] MAYO CLINIC, EEG (electroencefalograma), Ciencia, Abril 2020. Disponible en <https://www.mayoclinic.org/es-es/tests-procedures/eeeg/about/pac-20393875>
- [4] DELGADO K. LEDESMA S. & ROSTRO H., Análisis de electroencefalograma usando redes neuronales artificiales, Ciencia, 2019, Disponible en <http://www.scielo.org.mx/pdf/au/v29/2007-9621-au-29-e1672.pdf>
- [5] CRAIK A. HE Y. & CONTRERAS J., Deep learning for electroencephalogram (EEG) classification tasks: a review, Ciencia, Febrero 2019, Disponible en <https://iopscience.iop.org/article/10.1088/1741-2552/ab0ab5/pdf>
- [6] GONG S. XING K. CICHOCKI A. & LI J., Deep Learning in EEG: Advance of the Last Ten-Year Critical Period, Ciencia, 2021, Disponible en: <https://ieeexplore.ieee.org/ielx7/7274989/7422051/09430619.pdf>
- [7] SAHA S., A comprehensive guide to convolutional neural networks - the ELI5 way, Ciencia, 2018, Disponible en: <https://towardsdatascience.com/a-comprehensive-guide-to-convolutional-neural-networks-the-eli5-way>
- [8] MOCTEZUMA L. & MOLINAS M., EEG Channel-Selection Method for Epileptic-Seizure Classification Based on Multi-Objective Optimization, Ciencia, Junio 2020, Disponible en: <https://www.frontiersin.org/articles/10.3389/fnins.2020.00593/full>
- [9] ÁPICE, ASOCIACIÓN ANDALUZA DE EPILEPSIA, ¿Qué es la Epilepsia?, Salud, S/F, Disponible en <https://www.apiceepilepsia.org/que-es-la-epilepsia/que-es-la-epilepsia-definicion/>
- [10] ILAE, ILAE official report: a practical clinical definition of epilepsy, Salud, Disponible en <https://onlinelibrary.wiley.com/doi/full/10.1111/epi.12550>
- [11] INSTITUTO NACIONAL DE CÁNCER, Electroencefalograma, S/F, Salud, Disponible en <https://www.cancer.gov/espanol/publicaciones/diccionarios/diccionario-cancer/def/electroencefalograma>
- [12] ALOATBY T., EL-SAMIE F. & ALSHEBEILI S, Eurasip Journal on Advances in Signal Processing, A review of channel selection algorithms for EEG signal processing, Salud, 2015.
- [13] MICHAEL C. BRUNET D., EEG source imaging: A practical review of the analysis steps, Ciencia, 2019
- [14] GOLDBERGER, A., et al. "PhysioBank, PhysioToolkit, and PhysioNet: Components of a new research resource for complex physiologic signals. Circulation [Online]. 101 (23), pp. e215-e220."(2000)
- [15] MERRIAM-WEBSTER, Medical Dictionary, S/F, Salud, Disponible en <https://www.merriam-webster.com/medical/interictal>
- [16] MULA, M, Epilepsy & Behaviour, Pre-ictal psychiatric symptoms, Salud, Agosto 2013, Disponible en [https://www.epilepsybehavior.com/article/S1525-5050\(12\)00242-9/fulltext#relatedArticles](https://www.epilepsybehavior.com/article/S1525-5050(12)00242-9/fulltext#relatedArticles)
- [17] KANNER A. & HESDORFFER D., Handbook of Clinical Neurology, Salud, 2012, Disponible en <https://www.sciencedirect.com/science/article/abs/pii/B9780444528919000786>
- [18] PANAYU K, NATTAPONG T, MASAYUKI N & BOONSERM K, A Comparative Study of Window Size and Channel Arrangement on EEG-Emotion Recognition Using Deep CNN, Ciencia, Marzo 2021, Disponible en <https://www.mendeley.com/catalogue/47c5aab8-66e5-3efd-a17e-d3f4ebcbf137/>
- [19] BROWNLEE J, A Gentle Introduction to the Rectified Linear Unit (ReLU), Ciencia, Enero 2019, Disponible en <https://machinelearningmastery.com/rectified-linear-activation-function-for-deep-learning-neural-networks/>
- [20] BAI A & SKEIDE K, Method for Semi-Automated Evaluation of User Experience Using Brain Activity, Salud, Enero 2018, Disponible en https://www.researchgate.net/publication/328611869_Method_for_Semi-Automated_Evaluation_of_User_Experience_Using_Brain_Activity
- [21] PYTORCH, Adam, Tecnología, 2019, Disponible en <https://pytorch.org/docs/stable/generated/torch.optim.Adam.html#torch.optim.Adam>
- [22] S/A, Optimización de descenso de gradiente de Code Adam desde cero, Tecnología, Diciembre 2020, Disponible en <https://topbigdata.es/optimizacion-de-descenso-de-gradiente-de-code-adam-desde-cero>

- [23] BROWNIE J, Understand the Impact of Learning Rate on Neural Network Performance, Tecnología, Septiembre 2020, Disponible en <https://machinelearningmastery.com/understand-the-dynamics-of-learning-rate-on-deep-learning-neural-networks/>
- [24] BROWNLEE J, A Gentle Introduction to Pooling Layers for Convolutional Neural Networks, Tecnología, Julio 2019, Disponible en <https://machinelearningmastery.com/pooling-layers-for-convolutional-neural-networks/>
- [25] POKHARNA H, Convolutional Neural Networks, Tecnología, Julio 2016, Disponible en <https://medium.com/technologymadeeasy/the-best-explanation-of-convolutional-neural-networks-on-the-internet-fbb8blad5df8>